

Procesamiento de imágenes utilizando Deep Learning y Carla Simulator

Image processing with Deep Learning and Carla Simulator

Gatica, Isaias

isaiasgatica1@gmail.com

Saez, Lautaro Andres

lautaroandressaez@gmail.com

Resumen—En este informe se presenta la implementación de una red Pix2Pix capaz de pasar de una imagen RGB a una imagen segmentada donde cada color indica un objeto diferente. Se comenzara desde cero obteniendo el dataset mediante el simulador CARLA para luego poder entrenar la red con una gran variedad de imagenes con diferente clima y vegetación. Finalmente se probara con imagenes reales para analizar la viabilidad de entrenar una red con un simulador y luego ingresarla en el mundo real.

Resumen—This report presents the implementation of a Pix2Pix network capable of going from an RGB image to a segmented image where each color indicates a different object. It will start from scratch obtaining the dataset using the CARLA simulator to then be able to train the network with a great variety of images with different climate and vegetation. Finally, it will be tested with real images to analyze the viability of training a network with a simulator and then enter it into the real world.

Keywords— Pix2Pix, CNN, GAN, RNN, NN, YOLO, SOM, CARLA

I. INTRODUCCIÓN

Con la intención de brindarle inteligencia a un automovil, la primer cuestión es cómo éste se comunica con el mundo y cómo lo interpreta. Con el avance de la tecnología las cámaras toman preponderancia como sensores y combinando esta gran fuente de información (la fotografía) con un algoritmo de segmentación las posibilidades de detección y decisión del vehículo parten de una buena base.

¿Pero cómo generar esta segmentación de forma automática y confiable? En los ultimos años, debido a la necesidad de resolver cada vez mas complejos y la posibilidad de utilizar GPU's las redes neuronales han cobrado gran importancia en nuestras vidas, y ya son parte del día a día, cosas tan simples como los filtros de Instagram basan su reconocimiento facial en redes neuronales.

Las redes permiten resolver problemas que van desde la clasificación de imagenes hasta la conducción autónoma, claro esta que para esto existen diferentes arquitecturas las cuales son especificas para determinadas tareas, como el procesamiento de imagenes (CNN, GAN, YOLO), procesamiento de texto (RNN), procesamiento de datos (NN).

La desventaja principal de estos modelos supervisados es la necesidad de una dataset muy bien estructurado y para el cual es necesario el trabajo humano, esta es la tarea mas importante y que si esta mal realizada el red no tendra un desempeño correcto.

Aquí es donde nace el uso de simuladores. En el paper *Driving to Safety* de las autoras Nidhi Kalra y Susan M. Paddock, se plantean la siguiente cuestión “los vehículos autónomos deberán ser conducidos

cientos de millones de millas y, a veces, cientos de miles de millones de millas para hacer afirmaciones estadísticamente confiables sobre la seguridad”. Esto conlleva obviamente muchos gastos y riesgos, lo que un simulador reduce de gran manera, no solo para la creación del dataset si no tambien para el posterior testeo de la conducción autónoma.

II. MATERIAS Y METODOS

En esta sección se detallan los recientes avances en los campos de interes.

II-A. CARLA

CARLA [3] es un simulador de conducción el cual posee una API para Python lo que permite de forma sencilla obtener datos del entorno. Esto permite una gran simpleza a la hora de crear dataset o probar modelos de AI.

CARLA cuenta con una gran variedad de sensores como GPS, LiDAR, camaras RGB, camaras de segmentación semantica, etc. También posee un ambiente muy variado, permitiend variaciones en la neblina, la hora del día e incluso el clima.

II-B. Deep Learning

Las redes neuronal son muy utilizadas en el campo de la minería de datos, debido a su gran versatilidad. Dentro de este mundo existen 2 grandes tipos de entrenamientos para los supervisados que dada una entrada X se conoce la salida deseada Y y otros casos los algoritmos no supervisados como los modelos de Q-learning o los mapas autoorganizados (SOM). En este proyecto se opto por un entrenamiento supervisado.

Para el modelado de la red neuronal se utilizó un modelo llamado Pix2Pix [5]. El cual pertiene dada una imagen de entrada X obtener una imagen de salida Y .

Este modelo consta de 2 redes separadas, la primera se denominada el generador Fig.1 el cual deberá aprender a segmentar la imagen semanticamente. Y la segunda se llama el discriminador Fig.2 este se encarga de correguir al generador aprendiendo cuando una salida es realista”. Llamaremos salida realista.^a aquella imagen que cumpla el objetivo esperado, en este caso sería una imagen segmentada de coherente.

II-B1. Generador: El generador cuenta con una arquitettura denominada U-net [4], la cual tiene la cual posee una muy buena eficiencia debido a los bypass que existen entra las capas de convolución y las capas de deconvulación. Con la finalidad de comprender de forma mas sencilla se puede observar en la Fig.3 dicha arquitectura.

El error del generador es cuantizado por la red discriminativa.



Figura 1. Esquema de la red generativa.




Figura 2. Esquema de la red discriminativa.

II-B2. Discriminador: El discriminador posee una arquitectura mucho mas sencilla, la cual consta de 6 capas de convolución. Esto se debe a que la salida representa que tan realista es un segmento de la imagen de entrada. El error del discriminador se cuantiza mediante una entropía cruzada. Ya que se propone que siempre que le entre una imagen del generador la salida debe ser una matriz de 0, ya que esta imagen no es del dataset, mientras que cuando la entrada sea una imagen del dataset el resultado debe ser un 1.

Estodesemboca en una pelea entre en generador ya que debe aprender a engañar al discriminador y el discriminador que debe lograr siempre reconocer que la imagen \hat{Y} es totalmente falsa, ya que es una creación de la red generativa.

II-C. Preprocesado de los datos

Un paso fundamental para trabajar con algoritmos de imagenes es pasar del dominio $[0; 255]$ a un dominio mas acotado, para este trabajo se utilizo el domino de $[-1; 1]$. De esta forma se logra una mayor eficiencia computacional.

Debido al tamaño de las imagenes es recomendable hacer un resize a dimensiones mas pequeñas para disminuir el uso de RAM cuando son cargadas en memoria y el uso de GPU al realizar las convoluciones. En este caso las imagenes de entrada y de salida son redimensionadas a 256×256 .




Figura 3. Arquitectura de una U-net.




Figura 4. Visualización del stack previo al random jitter.



Figura 5. Visualización del random jitter.

II-C1. Random jitter: El *random jitter* es un proceso por el cual se busca realizar un aumento del dataset, esto disminuye la posibilidad de experimentar **overfitting**. Este proceso cuenta de 2 pasos:

Crop Se realiza un resize a 286×286 para luego realizar un recorte a 25×256 .

Flip De forma aleatoria con probabilidad 0,5 se realiza un rotación de 180° .

Debido a que es utilizada en algoritmos supervisados es necesario aplicar el *random jitter* tanto a la imagen de entrada como a la de salida, para ello se hace un stack de las mismas como se observa en la Fig.4.

En la Fig.5 se observa el proceso de random jitter completo.

Figura 6. Imágenes de muestra del dataset

III. PROPUESTA

Se propone realizar una red neuronal utilizando la arquitectura Pix2Pix que aprenda a segmentar semánticamente una imagen. Adicionalmente el dataset utilizado será obtenido mediante el CARLA permitiendo de esta forma pasar por todo el trayecto del diseño de una red que resuelve un nuevo problema. Este proceso consta de

1. Definir la arquitectura a utilizar.
2. Crear un dataset util para solucionar el problema.
3. Entrenar la red.
4. Testear el rendimiento de la misma.
5. Realizar mejoras a la arquitectura para obtener alguna de las siguientes ventajas:
 - Mayor velocidad de procesado.
 - Mejor rendimiento.
 - Eliminar el overfitting o underfitting si existiera.
6. Repetir los pasos anteriores hasta lograr un resultado satisfactorio.

IV. PRUEBAS Y RESULTADOS

Se presentara de forma ordena todas las etapas del proyecto. Debido a la cantidad de imagenes utilizadas no es posible presentarlas a todas, por ello se relizaran analisis particulares para algunos casos de interes.

IV-A. Obtención del dataset

Para obtener el dataset se colocaron una camara RGB y una camara de segmentación semántica [2], ubicadas en la misma posición. Se recolectaron los datos cada 5 segundos. Las condiciones climaticas utilizadas fueron aleatorias, lo que se logra obtener un dataset mucho mas variado, una representación de este puede observarse en Fig.6.

Para lograr un manejo autónomo del vehículo se utilizó el autopilot [1]. Con la finalidad de aumentar la variedad de imágenes se utilizaron todos los mapas posibles y se adicionaron otros vehiculos autónomos junto a personas. Aunque debido a limitaciones de hardware solo se pudieron ingresar 20 personas, lo cual provocó una deficiencia en la detección de personas de la red Pix2Pix.

IV-B. Entrenamiento de la red

Como fue mencionado en el marco teórico el modelo implementado se denomina Pix2Pix [5]. Se utilizó como entrada la imagen de la camara RGB y la salida será una imagen segmentada, para ello se utilizó el dataset obtenido con el simulador de CARLA el cual posee 8000 imagenes.

IV-B1. Tratamiento de las imagenes: Para evitar problemas en el entrenamiento de la red es muy usual llevar los valores de cada canal al intervalo $[-1; 1]$, esto evita problemas de continuidad en red. Luego se procede a aplicar un *random jitter*.

El dataset fue dividido en 2 partes una utilizada para el entrenamiento, aproximadamente el 80 % de las imagenes y otra parte para el testing de la red utilizando el 20 % restante, siguiendo el principio de Pareto.

IV-B2. Entrenamiento: Para realizar el entrenamiento se utilizó el dataset de testing, aproximadamente 6400 imagenes, y se realizaron 400 iteraciones a la red para lograr un mejor desempeño. A continuación se muestran 2 casos de interes debido a la gran densidad del dataset de testing.

En la Fig.7 se muestra una comparación para 1 imagen del dataset de testing luego de la primera iteración y al finalizar el entrenamiento. Puede observarse que existieron grandes mejoras sobre todo en la zona de la palmera donde al finalizar el entrenamiento es posible observar los detalles de la misma. Aunque cabe destacar que debido a la poca cantidad de señales de trafico en el dataset se observa que




Figura 7. Imagen del dataset de testing con señal de trafico.

si bien reconoce la estructura del semaforo no es capaz de utilizar el color adecuado.

Al analizar otro imagen del dataset la cual se observa en la Fig.8 se puede ver que la persona no es detectada, esto se le atribuye a la poca densidad de imagenes con personas que había en el dataset.

IV-C. Imágenes reales

En este apartado se muestran 2 imagenes de interes para mostrar el comportamiento del modelo entrenado en situaciones reales.

En la Fig.9 se observa como para un cielo despejado la red es capaz de detectar de forma muy eficiente los limites. Al analizar la palmera se observa un resultado muy similar. Pero para zonas con



Figura 8. Imagen del dataset de testing con persona.

mayor detalle se observa una deficiencia de la red, tal como sucede con los autos o los arbustos del costado izquierdo. Por otro lado en la Fig.10 como el cielo esta nublado la red tiene grandes problemas para delimitar las fronteras. Aunque se observa un buen resultado en la delimitación de los arboles del fondo, si bien el color no es el adecuado la red logra detectar las señales de trafico en ambas imagenes.

V. CONCLUSIONES

Al analizar los resultados del modelo con las imagenes que se obtienen desde el simulador se observa un desempeño correcto. Aun que existen ciertos detalles tales como: personas, señales de transito y paradas de colectivo. Estos problemas se adjudican a la poca densidad de estos en el dataset de training. En el caso de las personas existe una limitación por parte del simulador ya que no deja ingresar mas de 20. Los otros problemas son asociados a los mapas y la cantidad de señales de trafico que estos presentan, una posible solución sería



Figura 9. Imagen real y su respectiva segmentación semantica por la red luego del entrenamiento.

aumentar el tamaño del dataset o utilizar una red especializada en detección de señales de trafico.

Para las imagenes reales si bien el desempeño de la red disminuye y se observan otros problemas como las nubes los resultados generales dan esperanza sobre futuras redes entrenadas en simuladores para luego pasarlas a un entorno real. Un gran problema y que aun no ha sido solucionado es la iluminación, debido a su alta complejidad. Estas diferencias entre la realidad y el simulador desemboca en regiones que no son delimitadas de forma correcta y colores erroneos. Aunque las regiones de mayor interes son detectadas como la calle, la vereda y los autos, pero no bien delimitadas. Esto nos permitiria realizar una aproximación de donde se ubican los puntos de interes como otros vehiculos.

V-A. Ventajas

A continuación se nombrarán algunas ventajas de realizar la segmentación semántica, en particular con un simulador y una red Pix2Pix. Ordenadas según importancia decreciente:

1. Posibilidad de reconocer objetos o zonas de una forma mucho mas sencilla.



Figura 10. Imagen real junto a su representación segmentada por la red.

2. Al utilizar un simulador la principal ventaja recae en la posibilidad de crear un dataset con el mínimo esfuerzo humano, tiempo y costo monetario.
3. Gran flexibilidad de simular situaciones externas o propias del vehículo mientras se recolectan datos. Permitiendo simular situaciones anómalas.
4. Al utilizar redes neuronales no existe una etapa de diseño de descriptores, ya que estos son obtenidos por la red.
5. Reducción del tiempo de procesamiento de información.
6. Las imágenes semánticas ocupan menos espacio en memoria que su equivalente en RGB.

V-B. Desventajas

Por otro lado al analizar las desventajas de este modelo con el mismo criterio obtenemos:

1. Existe una diferencia significativa entre el entorno simulado y el real.
2. Limitaciones de las computadoras actuales para realizar procesos de simulación y train en forma simultanea.
3. Alto costo computacional.
4. Para problemas de alta complejidad y modelos de gran densidad es necesario datasets de gran tamaño.

5. Tiempo de generado del dataset.

Finalmente, estas practicas son de suma importancia en la actualidad debido a que permiten entrenar modelos por costos mucho menores. Adicionalmente se debido a la revolución de las redes neuronales a partir del 2009 y el aumento en la demanda de modelos para resolver todo tipo de tareas hoy en día es muy necesario la reducción de costes y de tiempos de creación tanto del dataset como el proceso de entrenamiento del modelo. Si bien los resultados obtenidos para imagenes reales todavia no estan cerca de poder reemplazar los obtenidos con dataset de imagenes reales, se observan resultados aceptables.

REFERENCIAS

- [1] "Carla api documentation," https://carla.readthedocs.io/en/latest/python_api/.
- [2] "Carla sensors reference," https://carla.readthedocs.io/en/latest/ref_sensors/.
- [3] "CARLA simulator," <https://carla.org/>.
- [4] "U-net architecture," <https://en.wikipedia.org/wiki/U-Net>.
- [5] Phillip.I, J.Zhu, T.Zhou, and A.A.Efros, "Image-to-image with conditional adversarial networks," 2018.