

Procesamiento de imágenes utilizando Deep learning y Carla Simulator

Gatica, Isais
email: isaiasgatica1@gmail.com
Saez, Lautaro Andres
email: lautaroandressaez@gmail.com

Resumen—En este informe se presenta la implementación de una red Pix2Pix capaz de pasar de una imagen RGB a una imagen segmentada donde cada color indica un objeto diferente. Se comenzara desde cero obteniendo el dataset mediante el simulador CARLA para luego poder entrenar la red con una gran variedad de imagenes con diferente clima y vegetación. Finalmente se probara con imagenes reales para analizar la viabilidad de entrenar una red con un simulador y luego ingresarla en el mundo real.

I. Introducción

En los ultimos años, debido a la necesidad de resolver cada vez mas complejos y la posibilidad de utilizar GPU's las redes neuronales han cobrado gran importancia en nuestras vidas, y ya son parte del día a día, cosas tan simples como los filtros de Instagram basan su reconocimiento facial en redes neuronales.

Las redes permiten resolver problemas que van desde la clasificación de imagenes hasta la conducción autonoma, claro esta que para esto existen diferentes arquitecturas las cuales son especificas para determinadas tareas, como el procesamiento de imagenes (CNN, GAN, YOLO), procesamiento de texto (RNN), procesamiento de datos (NN).

La desventaja principal de estos modelos supervisados es la necesidad de una dataset muy bien estructurado y para el cual es necesario el trabajo humano, esta es la tarea mas importante y que si esta mal realizada el red no tendra un desempeño correcto.

II. Marco Teórico

En esta sección se hara un breve marco teórico de los conceptos basicos que se utilizaran en el proyecto.

II-A. Deep Learning

Las redes neuronal son muy utilizadas en el campo de la minería de datos, debido a su gran versatilidad. Dentro de este mundo existen 2 grandes tipos de entrenamientos para los supervisados que dada una entrada X se conoce la salida deseada Y y otros casos los algoritmos no supervisados como los modelos de Q-learning o los mapas autoorganizados (SOM). En este proyecto se opto por un entrenamiento supervisado.

Para el modelado de la red neuronal se utilizó un modelo llamado Pix2Pix [4]. El cual pertine dada una imagen de entrada X obtener una imagen de salida Y .



Figura 1. Esquema de la red generativa.



Figura 2. Esquema de la red discriminativa.

Este modelo consta de 2 redes separadas, la primera se denominada el generador Fig.1 el cual deberá aprender a segmentar la imagen semanticamente. Y la segunda se llama el discriminador Fig.2 este se encarga de correguir al generador aprendiendo cuando una salida es realista^a. Llamaremos salida realista.^a aquella imagen que cumpla el objetivo esperado, en este caso sería una imagen segmentada de coherente.

II-A1. Generador: El generador cuenta con una arquitectura denomina U-net [3], la cual tiene la cual posee una muy buena eficiencia debido a los bypass que existen entra las capas de convolución y las capas de deconvolución. Con la finalidad de comprender de forma mas sencilla se puede observar en la Fig.3 dicha arquitectura.

El error del generador es cuantizado por la red discriminativa.

II-A2. Discriminador: El discriminador posee una arquitectura mucho mas sencilla, la cual consta de 6 capas de convolución. Esto se debe a que la salida representa que tan realista es un segmento de la imagen de entrada. El error del discriminador se cuantiza mediante una entropía cruzada. Ya que se propone que siempre que le entre una imagen del generador la salida debe ser una matriz de 0,




Figura 3. Arquitectura de una U-net.

ya que esta imagen no es del dataset, mientras que cuando la entrada sea una imagen del dataset el resultado debe ser un 1.

Estodesemboca en una pelea entre en generador ya que debe aprender a engañar al discriminador y el discriminador que debe lograr siempre reconocer que la imagen \hat{Y} es totalmente falsa, ya que es una creación de la red generativa.

II-B. Preprocesado de los datos

Un paso fundamental para trabajar con algoritmos de imagenes es pasar del dominio $[0; 255]$ a un dominio mas acotado, para este trabajo se utilizo el domino de $[-1; 1]$. De esta forma se logra una mayor eficiencia computacional.

Debido al tamaño de las imagenes es recomendable hacer un resize a dimensiones mas pequeñas para disminuir el uso de RAM cuando son cargadas en memoria y el uso de GPU al realizar las convoluciones. En este caso las imagenes de entrada y de salida son redimensionadas a 256×256 .

II-B1. Random jitter: El random jitter es un proceso por en el cual se busca realizar un aumentado del dataset, esto disminuye la posibilidad de experimentar overfitting. Este proceso cuenta de 2 pasos:

Crop Se realiza un resize a 286×286 para luego realizar un recorte a 25×256 .

Flip De forma aleatoria con probabilidad 0,5 se realiza un rotación de 180° .

Debido a que es utiliza en algoritmos supervisados es necesario aplicar el random jitter tanto a la imagen de entrada como a la de salida, para ello se hace un stack de las mismas como se observa en la Fig.4.

En la Fig.5 se observa el proceso de random jitter completo.

III. Desarrollo

Se presentara de forma ordena todas las etapas del proyecto. Debido a la cantidad de imagenes utilizadas no es posible presentarlas a todas, por ello se relizaran analisis particulares para algunos casos de interes.




Figura 4. Visualización del stack previo al random jitter.




Figura 5. Visualización del random jitter.

III-A. Obtención del dataset

Para obtener el dataset se colocaron una camara RGB y una camara de segmentación semántica [2], ubicadas en la misma posición. Se recolectaron los datos cada 5 segundos. Las condiciones climaticas utilizadas fueron aleatorias, lo que permite obtener un dataset mucho mas variado Fig.6.

Para lograr un manejo autónomo del vehículo se utilizó el autopilot [1]. Con la finalidad de aumentar la variedad de imágenes se utilizaron todos los mapas posibles y se adicionaron otros vehiculos autónomos junto a personas. Aunque debido a limitaciones de hardware solo se pudieron ingresar 20 personas, lo cual provocó una deficiencia en la detección de personas de la red Pix2Pix.

III-B. Entrenamiento de la red

Como fue mencinado en el marco teórico el modelo implementado se denomina Pix2Pix [4]. Se utilizó como entrada la imagen de la camara RGB y la salida será una imagen segmentada, para ello se utilizó el dataset obtenido con el simulador de CARLA el cual posee 8000 imagenes.

III-B1. Tratamiento de las imagenes: Para evitar problemas en el entrenamiento de la red es muy usual llevar los valores de cada canal al intervalor $[-1; 1]$, esto evita problemas de continuidad en red. Luego se procede a aplicar un random jitter.

El dataset fue dividido en 2 partes una utilizada para el entrenamiento, aproximadamente el 80 % de las imagenes y otra parte para el testing de la red utilizando el 20 % restante, siguiendo el principio de Pareto.

III-B2. Entrenamiento: Para realizar el entremiento se utilizó el dataset de testin, aproximadamente 6400 imagenes, y se realizan 400 iteración a la red para lograr un mejor desempeño.

En la Fig.7 se muestra una comparación para 1 imagen del dataset de testing luego de la primera iteración y al finalizar el entrenamiento. Puede observarse que existieron

Figura 6. Imagenes de muestra del dataset

grandes mejoras sobre todo en la zona de la palmera donde al finalizar el entrenamiento es posible observar los detalles de la misma. Aunque cabe destacar que debido a la poca cantidad de señales de tráfico en el dataset se observa que si bien reconoce la estructura del semáforo no es capaz de utilizar el color adecuado.




Figura 7. Imagen del dataset de testing.

Al analizar otra imagen del dataset la cual se observa en la Fig.?? COMPLETAR!!!

IV. Resultados

En esta sección se verán los resultados obtenidos tanto para imágenes del simulador como para imágenes reales. Además se dejará un link de un video demostrativo.

IV-A. Imágenes del simulador

IV-B. Imágenes reales

V. Conclusiones

Observando la ?? se puede concluir que los resultados son bastante precisos si lo comparamos con la imagen semántica del simulador. Si bien ciertos detalles como las paradas de colectivo, señales de tránsito o peatones no los reconoce o si lo hace no le asigna el color adecuado, en las regiones más significativas como los autos, la calle o la vereda logra un desempeño bastante aceptable. Por otro lado, en la ?? donde se analiza a la red con imágenes reales, se observa que existen más errores a la hora de segmentar. Hay regiones que no se delimitan correctamente y/o colores que no son los adecuados. Por ejemplo la mancha azul en los arbustos de la primera imagen. Las regiones más significativas en este caso logran un resultado semi aceptable que aun así se podrían utilizar para darle redundancia al sistema autónomo. Lo más probable es que estos errores se deban a la diferencia de iluminación y la cantidad de detalles que tiene una imagen real en comparación con las imágenes de CARLA.

V-1. Ventajas: A continuación se nombrarán algunas ventajas de realizar la segmentación semántica, en particular con un simulador y una red Pix2Pix:

1. La ventaja principal que tiene segmentar semánticamente una imagen es la posibilidad de reconocer objetos o zonas de una forma mucho más sencilla ya sea para un usuario o para un software. Una ventaja secundaria de las imágenes semánticas es que ocupan

menos espacio en memoria que su equivalente en RGB.

2. Al utilizar un simulador la principal ventaja recae en la posibilidad de crear un dataset con el mínimo esfuerzo humano, tiempo y costo monetario. Por otro lado, a la hora de recolectar información el simulador permite una gran flexibilidad de simular situaciones externas o propias del vehículo. Poder variar el clima, el mapa, la velocidad del auto de prueba o los de la ciudad, entre otras muchas características. Esto nos permite simular situaciones anómalas y así crear un dataset mucho más variado.
3. La implementación de una red Pix2Pix para realizar la segmentación semántica tiene como principal ventaja....

V-2. Desventajas: Teniendo en cuenta las ventajas mencionadas anteriormente, veremos las desventajas o inconvenientes:

- La principal desventaja de utilizar un simulador para esta tarea es la diferencia que se presenta entre el entorno simulado y el real. Como quedó evidenciado en los resultados, esta diferencia de entornos genera errores en la imagen final. Por otro lado, se necesitarían conocimientos de programación en simuladores para generar un entorno mucho más realista o con características particulares.
- A la hora de implementar la red neuronal las desventajas recaen en la cantidad de tiempo necesario para entrenarlas, el costo computacional y en particular ... Además, a la hora de entrenar a la red es necesario en la mayoría de los casos un dataset de gran tamaño y heterogéneo.

Por último, como conclusión general cabe destacar que este tipo de prácticas son muy importantes y utilizadas en la actualidad. Las redes neuronales están revolucionando la forma de trabajar y pensar en distintos ámbitos. En consecuencia, existen grandes costos tanto monetarios como temporales que provocan el generar un dataset. Debido a esto, el implementar un simulador que disminuya estos factores limitantes es una de las técnicas bien vistas al día de hoy.

Referencias

- [1] "Carla api documentation," https://carla.readthedocs.io/en/latest/python_api/.
- [2] "Carla sensors reference," https://carla.readthedocs.io/en/latest/ref_sensors/.
- [3] "U-net architecture," <https://en.wikipedia.org/wiki/U-Net>.
- [4] Phillip.I, J.Zhu, T.Zhou, and A.A.Efros, "Image-to-image with conditional adversarial networks," 2018.